

Declaracion de desviaciones OSF

Declaración de desviaciones respecto al protocolo pre-registrado

Registro OSF: <https://doi.org/10.17605/OSF.IO/82Q76> **Fecha de registro:** 2026-09-12, 19:50 **Fecha de ejecución del análisis:** 2026-09-13, 00:27 (posterior al registro)

Resumen

El análisis efectivamente ejecutado coincide con el diseño registrado en OSF en sus elementos centrales: comparación no experimental de dos grupos (RF humano vs. RF generado por LLM), evaluación ciega mediante rúbrica de 5 dimensiones en escala Likert 1-5, y comparación entre grupos.

Aclaración sobre la prueba estadística específica

El registro OSF especificó que se realizaría “un análisis descriptivo, evaluación del acuerdo entre evaluadores y comparación entre ambos grupos”, sin fijar de antemano el nombre exacto de la prueba de hipótesis a utilizar. Siguiendo el plan de análisis general de la guía de la asignatura (Sección 4.4), se aplicó la siguiente regla de decisión, definida antes de observar los resultados de la comparación:

- Se ejecutó la prueba de normalidad de Shapiro-Wilk por grupo y dimensión.
- Cuando ambos grupos no rechazaron la normalidad, se usó la prueba t de Student para muestras independientes.
- Cuando al menos un grupo rechazó la normalidad, se usó la prueba U de Mann-Whitney.

Esta regla se aplicó de forma consistente a las 6 dimensiones evaluadas (las 5 dimensiones individuales más el puntaje global), sin seleccionar la prueba después de observar si el resultado sería significativo. No se considera una desviación sustantiva del protocolo, sino la especificación operativa de un paso que el registro dejó en términos generales.

Acuerdo entre evaluadores — hallazgo no anticipado

El registro no fijó un umbral esperado de acuerdo inter-evaluador. El análisis mostró un acuerdo bajo (κ de Fleiss entre -0.01 y 0.17 según la dimensión). Este resultado se reporta tal como se obtuvo, sin ajustes, y se discute como limitación metodológica en la sección de amenazas a la validez del manuscrito.

Resultado principal

No se encontraron diferencias estadísticamente significativas entre RF humanos y RF generados por LLM en ninguna de las 5 dimensiones evaluadas (todos los valores $p > 0.05$; el más cercano a significancia fue consistencia interna, $p = 0.067$). Esto no permite rechazar H_0 . Se reporta como resultado principal del estudio, no como un análisis fallido.

Conclusión

No hubo desviaciones sustantivas respecto del diseño registrado. Las aclaraciones anteriores documentan decisiones operativas tomadas dentro del marco ya establecido en el pre-registro, antes de conocer los resultados.